

Modül 03 — Cevap Anahtarı

Veri görselleştirme: ggplot2

Prof. Dr. Hakan Mehmetcik

2026-09-10

Bu belge 03_modul_alistirmalar.qmd dosyasındaki 20 sorunun doğru cevaplarını ve gerekçelerini içerir. Gerekçeler yalnızca “doğru cevap bu” demekle kalmaz — **neden** doğru olduğunu da açıklar, çünkü sınavda sizden istenen de budur.

Bölüm A — Katmanlar ve Sözdizimi

1. Doğru cevap: b) R, bir ifadenin bittiğine satır sonunda karar verir. + satırın **başında** olduğu için R ilk satırı (`ggplot(...)`) tam bir ifade sayar ve onu çalıştırır: yalnızca eksenleri çizen, hiçbir geom içermeyen boş bir panel çizilir. İkinci satır, başında yalnız başına bir + işareti bulunan + `geom_point()` ifadesidir ve R bunu geçerli bir R ifadesi olarak yorumlayamayıp hata verir. Kural: + **satırın sonunda** durur.

2. Doğru cevap: b) `geom_point()` satırının sonunda + eksik. R grafiği burada tam bir ifade sayıp bitirir ve **hiçbir hata vermeden** çizer — ama başlıksız. Sonraki iki satır (`labs(...)` ve varsa `theme_minimal()`) ayrı bir ifade olarak sessizce çalışır ve ekrana hiçbir şey basmaz. Bu, hata mesajı vermediği için fark edilmesi en zor hatalardan biridir.

3. Doğru cevap: d) `geom_col()` hazır bir y değeri **bekler** ve her x kategorisi için tek bir y değeri olmasını varsayar. Veride aynı a değeri için birden fazla ham satır varsa (özetlenmemiş veri), `geom_col()` bu satırları üst üste yığar; bu, hataya değil ama genelde istenmeyen bir sonuca yol açar — asıl istenen önce `count()` veya `group_by()` |> `summarise()` ile özetlemektir. (a) yanlıştır: x her zaman kategorik olmak zorunda değildir. (c) tam tersine `geom_col()` için beklenen durumdur.

Bölüm B — Eşleme mi, Sabit Ayar mı?

4. **Doğru cevap: b)** `aes()` içindeki her şey **veri** olarak yorumlanır. "red" metni bir renk adı değil, bütün satırlarda aynı değeri taşıyan tek kategorili bir değişkendir. `ggplot2` bu tek kategoriye kendi varsayılan paletinin ilk rengini (kırmızı değil, pembemsi turuncu) atar ve kategorinin adını ("red") lejanta yazar.

5. **Doğru cevap: b)** Sabit bir değer, `aes()` **dışına**, `geom` fonksiyonunun kendi argümanı olarak yazılır: `geom_point(size = 3)`. (a) ve (c) `size`'ı veriye eşmiş gibi davranır ve anlamsız bir lejant üretir; (d) `ggplot2`'de böyle bir fonksiyon yoktur.

6. **Doğru cevap: a)** `shape` estetiği yalnızca **kategorik** değişkenlerle çalışır, çünkü şekiller sonlu ve sıralı olmayan bir kümedir (en fazla altı farklı şekil ayırt edilebilir). `lifeExp` sürekli sayısal bir değişken olduğu için `ggplot2` render sırasında "a continuous variable cannot be mapped to the shape aesthetic" hatası verir.

Bölüm C — Tek Değişkenin Dağılımı

7. **Doğru cevap: b)** Çok küçük bir `binwidth`, her çubuğu birkaç gözleme indirger; bu durumda dağılımın **gerçek yapısı** yerine örneklemden kaynaklanan rastgele iniş-çıkışlar öne çıkar. Çok büyük bir `binwidth` ise tam tersi bir hataya yol açar: yapıyı düzleştirip gizler. İkisi arasında, verinin gerçek desenini en dürüst gösteren bir orta nokta aranır.

8. **Doğru cevap: a)** Kod 1'de veri zaten `count()` ile özetlenmiş; her kıta için hazır bir sayı (`n`) var. `geom_bar()` ise arka planda her zaman kendi sayma işlemini (`stat = "count"`) çalıştırır ve bir `y` eşlemesi **kabul etmez**; `y = n` verildiği için R hata verir: "stat_count() must only have an x or y aesthetic." Kod 2'de veri hâlâ ham (her satır bir ülke) ve `y` hiç verilmemiş; `geom_bar()` `continent` sütununu kendisi sayar ve sorunsuz çalışır. Bir sütunu önceden saydıysanız (veya bir ortalama/toplam gibi hazır bir değeriniz varsa), `geom_bar()` yerine `geom_col()` kullanmanız gerekir.

9. **Doğru cevap: b)** Bıyıklar, kutunun (çeyrekler açıklığının) 1,5 katını aşmayan **en uç gözleme** kadar uzanır; mutlak minimum ve maksimuma değil. Bu sınırın ötesinde kalan gözlemler ayrı noktalar olarak, aykırı değer adayı diye işaretlenir.

Bölüm D — İki Sayısal Değişken

10. **Doğru cevap: c)** Rengi değiştirmek (örneğin hepsini kırmızı yapmak) üst üste binen noktaların sayısını **görünür kılmaz**; noktalar hâlâ birbirinin üstünde durur, yalnızca renk değişir. Saydamlık (a), titreştirme (b) ve boyutu küçültmek (d) üst üste binmeyi azaltan veya çakışan noktaları ayıran gerçek çözümlerdir.

11. **Doğru cevap: b)** `geom_abline(intercept = 0, slope = 1)`, veriden hesaplanan bir doğru değil, **teorik bir öngörü** (Gamson Yasası'nın “bakanlık payı = sandalye payı” iddiasını) grafiğe sabit bir referans olarak ekler. Veriden en iyi uyan doğruyu çizmek isteseydik `geom_smooth(method = "lm")` kullanırdık.

12. **Doğru cevap: b)** `coord_equal()`, iki eksenin bir biriminin ekranda eşit uzunlukta görünmesini sağlar. Bu, özellikle iki eksen aynı şeyi (örneğin ikisi de bir oranı) ölçtüğünde ve aralarındaki açısal ilişkinin (örneğin 45 derecelik bir referans doğrusunun) doğru görünmesi gerektiğinde önemlidir.

Bölüm E — Kategorik Değişkenler ve Konum Ayarları

13. **Doğru cevap: c)** `position = "fill"` her çubuğu %100'e tamamlar ve grup büyüklüğü bilgisini feda ederek **grup içi oranları** doğrudan karşılaştırılabilir kılar. `"stack"` toplam büyüklüğü gösterir ama iç oranları okumayı zorlaştırır; `"dodge"` mutlak sayıları yan yana koyar ama farklı büyüklükteki gruplar arasında oran karşılaştırmasını yanıltıcı hâle getirir.

14. **Doğru cevap: b)** R, bir karakter değişkeninin taşıdığı sıralı anlamı **bilemez**; varsayılan olarak bütün karakter/faktör değişkenlerini alfabetik sıralar. “Agree”, alfabetik sırada “Strongly agree”den önce geldiği için basamaklar mantıksal sıradan (katılmıyorumdan katılıyorum) kopar. Doğru sıralama, `factor(..., levels = ...)` ile elle verilmelidir.

15. **Doğru cevap: c)** `reorder(kategori, deger)`, kategorileri verilen sayısal değere göre (varsayılan olarak ortalamasına göre) yeniden sıralar ve bunu doğrudan `aes()` içinde kullanmanızı sağlar. `factor()` bir sıralama **belirtmenizi** sağlar ama sırayı sizin elle yazmanızı gerektirir; doğal bir sırası olmayan ama bir **değere göre** sıralanacak kategoriler için `reorder()` daha pratiktir.

Bölüm F — Zaman, Ölçekler ve Üçüncü Değişken

16. Doğru cevap: c) `gapminder` verisinde her yıl için 142 ülkenin 142 ayrı değeri vardır. `group` estetiği verilmediğinde `ggplot2`, hangi noktaların **aynı çizgiye** ait olduğunu bilemez ve bütün noktaları tek bir çizgide, yıl sırasına göre birleştirir; bu da anlamsız bir zikzak üretir. Doğrusu `aes(x = year, y = lifeExp, group = country)` ya da `color = country` (az sayıda ülke için) kullanmaktır.

17. Doğru cevap: b) `scale_x_log10()`, eşit **oranları** eşit mesafeye çevirdiği için sağa çarpık dağılımlarda (gelir, nüfus gibi) küçük değerleri birbirinden ayırt edilebilir kılar ve genellikle doğrusal olmayan bir ilişkiyi doğrusala yaklaştırır. (a) verinin yönünü tersine çevirir, çarpıklığı düzeltmez. (c) `sqrt` bazen işe yarasa da “her zaman log’dan iyi” iddiası yanlıştır; hangisinin uygun olduğu verinin çarpıklık derecesine bağlıdır.

18. Doğru cevap: b) `ggplot()` içinde (genel düzeyde) verilen bir eşleme **bütün katmanlara miras kalır**. `color = continent` genel düzeyde verildiği için hem `geom_point()` hem `geom_smooth()` bunu kullanır ve `geom_smooth(method = "lm")` **her kıta için ayrı** bir doğru hesaplar. Tek bir doğru istenseydi, rengi yalnızca `geom_point(aes(color = continent))` içine, yani yerel düzeye yazmak gerekirdi.

19. Doğru cevap: b) Bu, ders notlarındaki SAT örneğinin ta kendisidir: bir ilişki, veri **gruplara ayrıldığında yön değiştiriyor**. Buna Simpson paradoksu denir. Nedeni, üçüncü bir değişkenin (burada sınava giren öğrenci oranı) hem açıklayıcı hem yanıt değişkenini birlikte etkilemesidir.

20. Doğru cevap: c) Hazır bir tema (`theme_minimal()`) kendinden **önce** yazılmış özel `theme()` ayarlarını sıfırlar. Bu yüzden önce hazır temayı, sonra üzerine eklemek istediğiniz özel ayarları yazmalısınız. Ters sırada yazarsanız, `legend.position = "bottom"` ayarı `theme_minimal()` tarafından ezilir ve lejant varsayılan konumuna döner.