

Modül 04 — Aıştırmalar

Tanımlayıcı istatistik

Prof. Dr. Hakan Mehmetcik

2026-09-10

Bu Aıştırmalar Hakkında

Bu aıştırmalar **notlandırılmaz ve teslim edilmez**. Amacı, sınavdan önce kendi durumunuzu ölçebilmenizdir. Sınav soruları da bu biçimde (çoktan seçmeli, tek doğru cevap) kurgulanır.

Her soru 4 şıklıdır ve yalnızca **bir tanesi** doğrudur. Sınavda bilgisayar olmayacak; önce kâğıt üzerinde düşünün, R’da doğrulamayı sonraya bırakın.

Cevaplarımızı not edin, sonra `04_modul_cevap_anahtari.qmd` dosyasıyla karşılaştırın.

Bölüm A — Kategorik Değişkenler

1. `titanic |> count(embarked)` çalıştırıldığında elde edilen tablonun `n` sütunu neyi gösterir?

- a) Her limandan binen yolcuların yaşta ortalamasını
- b) Her liman kategorisinden kaç yolcu bindiğini (frekans)
- c) Her limanın toplam yolcu sayısına oranını (yüzde)
- d) Limanların alfabetik sırasını

2. Aşağıdaki kod bir hata vermeden çalışıyor ama `oran` sütunu her satırda **1.0** çıkıyor. Sorun nedir?

```
titanic |>
  count(pclass, survived) |>
  mutate(oran = n / sum(n))
```

- a) `count()` fonksiyonu `mutate()` ile birlikte kullanılamaz
- b) `sum(n)` tüm tablonun toplamını alıyor; `group_by(pclass)` eksik, her satır kendi grubundaki toplam yerine genel toplama bölünmeli
- c) `survived` bir faktör olmadığı için hesap yanlış çıkıyor
- d) `mutate()` yalnızca sayısal sütun eklerken kullanılır, oran hesaplarken kullanılamaz

3. `geom_bar(position = "fill")` ile `geom_bar(position = "stack")` (varsayılan) arasındaki temel fark nedir?

- a) `"fill"` çubukları yatay, `"stack"` dikey çizer
- b) `"stack"` mutlak sayıları üst üste yığar; `"fill"` her çubuğu %100'e tamamlayarak yalnızca oranı gösterir
- c) `"fill"` yalnızca iki kategoriyle çalışır
- d) İkisi arasında görsel bir fark yoktur, yalnızca renk paleti değişir

4. Titanic'te 1. sınıfta 216, 3. sınıfta 709 yolcu var. 1. sınıfın hayatta kalma oranı 3. sınıftan daha yüksek olduğu hâlde, mutlak sayıda hayatta kalan 3. sınıf yolcusu 1. sınıftan **fazla** olabilir. Bu, hangi ilkeyi gösterir?

- a) Verideki bir hatayı gösterir, böyle bir şey mümkün değildir
- b) Oran ve mutlak sayı farklı sorulara cevap verir; grup büyüklükleri farklıyken ikisi birbirinden bağımsız okunmalıdır
- c) `count()` fonksiyonunun yanlış kullanıldığını gösterir
- d) 3. sınıf yolcularının aslında daha güvende olduğunu gösterir

Bölüm B — Merkezi Eğilim

5. Bir değişkenin ortalaması medyanından belirgin şekilde **yüksekse**, bu genellikle neyin işaretidir?

- a) Değişken sola çarpıktır
- b) Değişken sağa çarpıktır (birkaç yüksek değer ortalamayı çekiyor)
- c) Değişkenin standart sapması sıfırdır
- d) Veride bir hesaplama hatası vardır

6. Bir ülkenin “ortalama hane geliri” 45.000 TL, “medyan hane geliri” ise 28.000 TL olarak açıklanıyor. Bir siyaset bilimci olarak bu iki sayı arasındaki farkı nasıl yorumlarsınız?

- a) İki sayı da aynı şeyi ölçtüğü için fark önemsizdir
- b) Hesaplama hatası olmalıdır, ikisi eşit çıkmalıydı
- c) Gelir dağılımı sağa çarpıktır; az sayıda yüksek gelirli hane ortalamayı yukarı çekiyor — medyan “tipik haneyi” daha iyi temsil eder
- d) Medyan yalnızca kategorik verilerde kullanılabildiği için burada geçersizdir

7. R'da `mode(x)` fonksiyonunu çalıştırdığımızda ne elde edersiniz?

- a) x değişkeninin istatistiksel modunu (en sık tekrar eden değeri)
- b) x 'in veri türünü ("numeric", "character" vb.) — istatistiksel mod için kendi fonksiyonunu yazmanız gerekir
- c) x 'in ortalamasını
- d) Bir hata mesajı, çünkü R'da böyle bir fonksiyon yoktur

8. Aşağıdaki değişkenlerden hangisi için **mod**, ortalama ve medyandan daha anlamlı bir merkezi eğilim ölçüsüdür?

- a) Ülkelerin kişi başı GSYİH'si
- b) Öğrencilerin sınav notları
- c) Bir mağazada en çok satılan ayakkabı numarası
- d) Bir şehrin günlük sıcaklık ortalaması

9. `gm2007 |> group_by(continent) |> summarise(m = mean(lifeExp))` kodu ne üretir?

- a) Tüm dünyanın tek bir ortalama yaşam beklentisini
- b) Her kıta için ayrı ayrı hesaplanmış ortalama yaşam beklentisini
- c) Her ülke için ayrı ayrı hesaplanmış ortalama yaşam beklentisini
- d) Bir hata, çünkü `summarise()` `group_by()` ile birlikte kullanılamaz

Bölüm C — Yayılım

10. Aralık (range) ölçüsünün en büyük zayıflığı nedir?

- a) Hesaplaması karmaşıktır
- b) Yalnızca kategorik verilerde kullanılabilir
- c) Tek bir aşırı (uç) değerden kolayca etkilenir, dağılımın geri kalanı hakkında bilgi vermez
- d) Negatif değerler için tanımsızdır

11. IQR (çeyrekler açıklığı), aralığa (range) göre neden genellikle tercih edilir?

- a) Hesaplaması aralıktan daha hızlıdır
- b) Ortadaki %50'lik dilime odaklandığı için uç değerlerden aralık kadar etkilenmez
- c) IQR her zaman aralıktan büyük çıkar
- d) IQR yalnızca simetrik dağılımlarda tanımlıdır

12. Standart sapmanın varyansa göre yorumlanması neden daha kolaydır?

- a) Standart sapma her zaman pozitifdir, varyans negatif olabilir
- b) Standart sapma, orijinal değişkenle aynı birimdedir; varyans karesi alınmış birimdedir
- c) Varyans yalnızca örneklerde, standart sapma yalnızca popülasyonlarda hesaplanır
- d) İkisi arasında yorum farkı yoktur, sadece isim farklıdır

13. İki ülkenin ortalama yaşam beklentisi aynı (75 yıl) ama biri düşük standart sapmaya, diğeri yüksek standart sapmaya sahip. Bu ne anlama gelir?

- a) İki ülke arasında hiçbir fark yoktur, ortalamalar eşit olduğu için dağılımlar da özdeştir
- b) Düşük standart sapmalı ülkede yaşam beklentisi bölgeler/gruplar arasında daha tutarlı; yüksek standart sapmalı ülkede daha farklılaşmış durumdadır
- c) Yüksek standart sapmalı ülkenin ortalaması yanlış hesaplanmıştır
- d) Standart sapma yalnızca gelir verisinde anlamlıdır, yaşam beklentisinde kullanılamaz

Bölüm D — Çarpıklık ve Basıklık

14. Bir dağılımda ortalama, medyandan **düşükse**, bu dağılım hakkında ne söyleyebiliriz?

- a) Dağılım sağa çarpıktır
- b) Dağılım sola çarpıktır — uzun kuyruk solda, düşük değerlerin çektiği birkaç aşırı gözlem var
- c) Dağılım kesinlikle simetriktir
- d) Bu durum matematiksel olarak imkânsızdır

15. “Leptokurtik” bir dağılımı diğerlerinden ayıran temel özellik nedir?

- a) Ortalamasının sıfır olması
- b) Sivri bir tepe ve kalın kuyruklara sahip olması — aşırı değer görülme olasılığının normal dağılıma göre daha yüksek olması
- c) Yalnızca pozitif değerler içermesi
- d) Kategorik bir değişken olması

16. Bir finansal getiri serisinin leptokurtik olduğu söyleniyor. Bu, bir analist için pratikte ne anlama gelir?

- a) Getiriler her zaman pozitifdir
- b) Aşırı kayıp/kazanç olayları, normal dağılım varsayımının önerdiğinden daha sık gerçekleşebilir — risk daha dikkatli değerlendirilmelidir
- c) Ortalama ve medyan birbirine tam olarak eşittir
- d) Standart sapma hesaplanamaz

Bölüm E — İlişki (Korelasyon)

17. $\text{cor}(x, y)$ fonksiyonu **-0.85** değerini döndürüyor. Bu ne anlama gelir?

- a) x , y 'ye neden olmaktadır
- b) x ile y arasında güçlü, negatif yönlü bir doğrusal ilişki vardır (biri artarken diğeri azalma eğilimindedir)
- c) x ile y arasında hiçbir ilişki yoktur
- d) Hesaplama da bir hata vardır, korelasyon negatif olamaz

18. `age` sütununda eksik değerler (NA) varken `cor(titanic$age, titanic$fare)` çalıştırıldığında sonuç NA çıkıyor. Bunu düzeltmek için hangi argüman eklenmelidir?

- a) `na.rm = TRUE`
- b) `use = "complete.obs"`
- c) `drop.na = TRUE`
- d) `missing = "ignore"`

19. Ülkelerin dondurma satışları ile boğulma vakaları arasında pozitif bir korelasyon bulunmuştur. En olası açıklama nedir?

- a) Dondurma yemek boğulmaya neden olur
- b) Boğulma vakaları dondurma satışını artırır
- c) Her iki değişken de üçüncü bir değişkenden (sıcak hava/yaz mevsimi) etkileniyor olabilir — bu bir karıştırıcı değişken örneğidir
- d) Korelasyon katsayısı yanlış hesaplanmış olmalıdır

20. İki değişken arasındaki `cor()` değeri **0.02** (sıfıra çok yakın) çıkıyor. Aşağıdakilerden hangisi **kesinlikle doğru** bir sonuçtur?

- a) İki değişken arasında hiçbir ilişki yoktur, doğrusal veya doğrusal olmayan
- b) İki değişken arasında güçlü bir *doğrusal* ilişki yoktur; ama doğrusal olmayan bir ilişki (örneğin U şeklinde) hâlâ var olabilir ve `cor()` bunu yakalamaz
- c) Değişkenlerden biri kategoriktir
- d) Hesaplama mutlaka yanlıştır