

Modül 04 — Cevap Anahtarı

Tanımlayıcı istatistik

Prof. Dr. Hakan Mehmetcik

2026-09-10

Bu belge 04_modul_alistirmalar.qmd dosyasındaki 20 sorunun doğru cevaplarını ve gerekçelerini içerir. Gerekçeler yalnızca “doğru cevap bu” demekle kalmaz — **neden** doğru olduğunu da açıklar, çünkü sınavda sizden istenen de budur.

Bölüm A — Kategorik Değişkenler

- Doğru cevap: b)** `count()`, her kategoriden kaç gözlem olduğunu sayar; `n` sütunu bu **frekanstır**. Oran (yüzde) elde etmek için ayrıca `mutate(oran = n / sum(n))` gerekir — bu, `count()`’un varsayılan çıktısında yoktur.
- Doğru cevap: b)** `sum(n)`, gruplanmamış tüm satırların toplamını alır; her satır kendi `pclass` grubu içindeki paya değil, **genel toplama** bölünür. Bu yüzden her `pclass` grubunun kendi içindeki `survived` oranları toplandığında 1.0 çıkar — istenen “her sınıf içinde hayatta kalma oranı” değil, “genel toplamın payı” hesaplanmış olur. Doğrusu, `count()`’tan sonra `group_by(pclass)` eklemektir (bkz. ders notu, çapraz tablo örneği).
- Doğru cevap: b)** “`stack`” (varsayılan), gruptaki mutlak sayıları üst üste yığar — çubuğun toplam yüksekliği grup büyüklüğünü yansıtır. “`fill`” her çubuğu %100’e tamamlar; böylece farklı büyüklükte gruplar (1. sınıfın 216, 3. sınıfın 709 yolcusu) **adil biçimde** karşılaştırılabilir, çünkü eksen artık mutlak sayı değil orandır.
- Doğru cevap: b)** Oran ve mutlak sayı farklı sorulara cevap verir: “Hangi grupta hayatta kalma **şansı** daha yüksekti?” sorusuna oran cevap verir; “Hayatta kalan **kaç kişi** vardı?” sorusuna mutlak sayı cevap verir. Grup büyüklükleri eşit olmadığında (216’ya karşı 709) bu iki soru farklı cevaplar üretebilir ve bu bir çelişki değildir.

Bölüm B — Merkezi Eğilim

5. Doğru cevap: b) Ortalama, tüm değerlerin toplamından hesaplandığı için birkaç **yüksek** değerden orantısız şekilde etkilenir ve yukarı çekilir; medyan bu değerlerden etkilenmez. Ortalama > medyan dağılımın sağında uzun bir kuyruk var demektir — **sağa çarpıklık**.

6. Doğru cevap: c) Gelir dağılımları neredeyse her zaman sağa çarpıktır: az sayıda çok yüksek gelirli hane, ortalamayı gerçek “tipik” haneden çok daha yukarı çeker. Medyan, sıralamanın tam ortasındaki haneyi gösterdiği için bu birkaç aşırı değerden etkilenmez ve “tipik hane”yi daha güvenilir temsil eder. Bu iki sayı arasındaki fark bir hata değil, dağılımın şekli hakkında bilgi verir.

7. Doğru cevap: b) R’da `mode()` **istatistiksel modu hesaplamaz** — bir nesnenin depolama türünü (`"numeric"`, `"character"`, `"list"` vb.) döndürür. İstatistiksel mod için hazır bir fonksiyon yoktur; ders notundaki gibi `table()` + `max()` ile kendi fonksiyonunuzu yazmanız gerekir. Bu, R’in en sık karıştırılan tuzaklarından biridir.

8. Doğru cevap: c) Ayakkabı numarası kategorik/ayrık bir değişkendir ve işletme için asıl anlamlı olan soru “hangi numara **en çok** satılıyor?” sorusudur — bu doğrudan moddur. Diğer üç seçenek (GSYİH, sınav notları, sıcaklık) sürekli sayısal değişkenlerdir; bu tür değişkenlerde her değer genelde bir kez görülür ve mod anlamını yitirir; ortalama veya medyan çok daha bilgilendiricidir.

9. Doğru cevap: b) `group_by(continent)`, sonraki `summarise()` işlemini **her kıta için ayrı ayrı** çalıştırır; sonuç, kıta başına bir satır olan bir özet tablosudur. `group_by()` ve `summarise()` birlikte kullanılmak üzere tasarlanmıştır — bu, 3. oturumda (dplyr) görülen temel bir kalıptır.

Bölüm C — Yayılım

10. Doğru cevap: c) Aralık yalnızca en büyük ve en küçük değere bakar; aradaki 1000 gözlemin nasıl dağıldığı hakkında hiçbir bilgi vermez. Tek bir hatalı girilmiş veya gerçekten aşırı bir değer, aralığı tamamen çarpıtabilir.

11. Doğru cevap: b) IQR yalnızca ortadaki %50’lik dilime (Q1–Q3) bakar; en uçtaki değerler bu hesaba hiç girmez. Bu yüzden birkaç aşırı değer olsa bile IQR nispeten kararlı kalır — aralığı aksine.

12. Doğru cevap: b) Varyans, sapmaların **karesi** alınarak hesaplandığı için birimi de karesi alınmış olur (örneğin “yıl²” gibi anlamsız bir birim). Standart sapma bu karekökü aldığı için orijinal değişkenin birimine geri döner (“yıl”) ve doğrudan yorumlanabilir.

13. Doğru cevap: b) Ortalamanın eşit olması, dağılımların özdeş olduğu anlamına gelmez. Düşük standart sapma, gözlemlerin ortalama etrafında sıkı kümелendiğini (tutarlılık); yüksek

standart sapma, gözlemlerin ortalamadan uzağa yayıldığını (farklılaşma, eşitsizlik) gösterir. Bu, merkezi eğilimin *tek başına* yeterli olmadığının klasik örneğidir.

Bölüm D — Çarpıklık ve Basıklık

14. Doğru cevap: b) Ortalama < medyan birkaç **düşük** değer ortalamayı aşağı çekiyor demektir; bu, dağılımın solunda uzun bir kuyruk olduğu anlamına gelir — **sola çarpıklık**. (5. sorudaki mantığın simetriğidir.)

15. Doğru cevap: b) Leptokurtik dağılımlar, normal dağılıma göre tepede daha sivri, kuyruklarda ise daha **kalındır** — yani aşırı uçtaki değerlerin görülme olasılığı normal dağılımın öngördüğünden daha yüksektir.

16. Doğru cevap: b) Leptokurtik bir getiri dağılımı, “kuyruk riskinin” (aşırı kazanç/kayıp olaylarının) normal dağılım varsayımıyla modellenen bir sistemin öngördüğünden daha sık gerçekleşebileceği anlamına gelir. Bu, finansal risk yönetiminde normal dağılım varsayımının neden tek başına yeterli görülmediğinin temel nedenlerinden biridir.

Bölüm E — İlişki (Korelasyon)

17. Doğru cevap: b) Korelasyonun işareti (negatif) yönü, mutlak değeri (0.85, 1’e yakın) ise gücü gösterir: x arttıkça y ’nin azalma **eğiliminde** olduğu güçlü bir doğrusal ilişki var demektir. (a) yanlıştır çünkü korelasyon tek başına asla nedensellik ispatlamaz.

18. Doğru cevap: b) `use = "complete.obs"`, yalnızca her iki değişkende de eksik olmayan (NA içermeyen) satırları kullanarak hesaplama yapar. `na.rm = TRUE` tek değişkenli fonksiyonlarda (`mean()`, `sd()` gibi) işe yarar ama `cor()` iki değişken arasındaki **eşleşmiş** gözlemlere ihtiyaç duyduğu için farklı bir argüman (`use=`) kullanır.

19. Doğru cevap: c) Bu, ders notunda vurgulanan **karıştırıcı değişken** durumunun klasik bir örneğidir: sıcak hava/yaz mevsimi hem dondurma satışını hem de yüzme/boğulma vakalarını artırır. İki değişken birbirinden bağımsız olarak üçüncü bir ortak nedenden etkileniyor; aralarındaki korelasyon gerçek ama doğrudan nedensel değildir.

20. Doğru cevap: b) `cor()` yalnızca **doğrusal** ilişkiyi ölçer. Sıfıra yakın bir değer, güçlü bir doğrusal ilişki olmadığını gösterir — ama örneğin U şeklinde (parabolik) güçlü bir doğrusal olmayan ilişki hâlâ mevcut olabilir ve `cor()` bunu tamamen kaçırır. Bu yüzden sayısal bir korelasyon değerine güvenmeden önce her zaman bir saçılım grafiğine bakmak gerekir.