

Modül 04: Tanımlayıcı İstatistik

Prof. Dr. Hakan Mehmetcik

2026-09-10

Tanımlayıcı İstatistik Nedir?

Bir veri setinde binlerce, hatta milyonlarca gözlem olabilir. 3. modülde **gapminder** veri setinin 1704 satırını tek tek okuyarak “dünya nasıl değişti?” sorusuna cevap veremezsiniz — göze çarpan bir grafiğe ya da birkaç sayıya ihtiyacınız vardır. **Tanımlayıcı (betimsel) istatistik**, tam olarak bunu yapar: bir değişkenin dağılımını, merkezini ve yayılımını az sayıda özet sayı veya tabloyla anlatılır kılar.

Bunu iki ailede ele alacağız:

1. **Kategorik değişkenler** için: frekans tabloları ve oranlar.
2. **Sayısal değişkenler** için: merkezi eğilim (ortalama, medyan, mod), yayılım (varyans, standart sapma, çeyrekler açıklığı) ve dağılımın şekli (çarpıklık, basıklık).

Sonda, iki sayısal değişken arasındaki ilişkiyi özetleyen bir ölçüye —korelasyona— de değineceğiz; ama bunun bir *nedensellik* iddiası olmadığını en baştan vurgulayalım.

Bu modülde iki veri seti kullanacağız: **gapminder** (3. modülden tanıdık — ülke, yıl, yaşam beklentisi, GSYİH), ve **Titanic yolcu listesi** (1309 yolcunun sınıfı, cinsiyeti, yaşı, bileti ve hayatta kalıp kalmadığı) — `data/titanic.csv` içinde, projeye yerel olarak dahil edilmiştir.

Titanic verisi bilgisayar bilimi çevrelerinde çoğunlukla bir “kim kurtulacak?” tahmin yarışması olarak bilinir; ama bir siyaset bilimci için asıl değeri başka yerededir. Bu, **felaket anında toplumsal tabakalaşmanın ve toplumsal cinsiyet rollerinin** kaydedildiği tarihsel bir veri setidir: filikalara erişim kimin parasına, kiminle seyahat ettiğine ve cinsiyetine bağlıydı. Aşağıdaki tablolar ve grafikler, “1912’de sosyal statü hayatta kalma şansını nasıl belirledi?” sorusuna istatistiksel bir cevap arayacak.

```
titanic <- read.csv(here("data", "titanic.csv"))
str(titanic[, c("pclass", "survived", "sex", "age", "fare", "embarked")])
```

```
'data.frame': 1309 obs. of 6 variables:
 $ pclass : int 1 1 1 1 1 1 1 1 1 1 ...
 $ survived: int 1 1 0 0 0 1 1 0 1 0 ...
 $ sex : chr "female" "male" "female" "male" ...
 $ age : num 29 0.917 2 30 25 ...
 $ fare : num 211 152 152 152 152 ...
 $ embarked: chr "S" "S" "S" "S" ...
```

Kategorik Değişkenler: Frekans ve Oran

Kategorik bir değişken için ilk soru her zaman aynıdır: **hangi kategoriden kaç tane var?** `dplyr::count()` bunu tek satırda verir.

```
titanic |>
  count(pclass, name = "n") |>
  mutate(oran = round(n / sum(n), 3))
```

pclass	n	oran
1	323	0.247
2	277	0.212
3	709	0.542

Yolcuların yaklaşık %54'ü 3. sınıfta seyahat ediyordu — Titanic'in sosyal kompozisyonu hakkında tek bir sayı bile fikir veriyor. Ama asıl ilgi çekici soru şu: **hayatta kalma sınıfa göre değişiyor muydu?** Bunun için iki kategorik değişkeni birlikte özetleyen bir **çapraz tablo** (kontenjans tablosu) kurarız.


```
titanic |>
  count(pclass, survived) |>
  group_by(pclass) |>
  mutate(oran = round(n / sum(n), 3)) |>
  ungroup()
```

pclass	survived	n	oran
1	0	123	0.381
1	1	200	0.619
2	0	158	0.570
2	1	119	0.430

pclass	survived	n	oran
3	0	528	0.745
3	1	181	0.255

Sayılar tek başına ikna edici değildir; bir çubuk grafik örüntüyü göz kırpmadan gösterir.


```
titanic |>
  mutate(
    sinif = factor(pclass, labels = c("1. sınıf", "2. sınıf", "3. sınıf")),
    durum = factor(survived, labels = c("Kaybedildi", "Hayatta kaldı"))
  ) |>
  ggplot(aes(x = sinif, fill = durum)) +
  geom_bar(position = "fill") +
  scale_y_continuous(labels = label_percent()) +
  scale_fill_manual(values = c("Kaybedildi" = "#8C8C8C", "Hayatta kaldı" = "#4C3A80")) +
  labs(x = NULL, y = "Yolcu oranı", fill = NULL,
       title = "1. sınıf yolcunun hayatta kalma şansı 3. sınıftan çok daha yüksekti") +
  theme_minimal(base_size = 11)
```



Figür 1: Yolcu sınıfına göre hayatta kalma oranı

`position = "fill"` her çubuğu %100'e tamamlar; böylece mutlak yolcu sayısı değil, **oran** karşılaştırılır — 1. sınıfta çok daha az yolcu olmasına rağmen (216'ya karşı 709), grafik hâlâ adil bir karşılaştırma sunar. Aynı mantık cinsiyet için de geçerlidir:

```
titanic |>
  mutate(durum = factor(survived, labels = c("Kaybedildi", "Hayatta kaldı"))) |>
  ggplot(aes(x = sex, fill = durum)) +
  geom_bar(position = "fill") +
  scale_y_continuous(labels = label_percent()) +
  scale_fill_manual(values = c("Kaybedildi" = "#8C8C8C", "Hayatta kaldı" = "#4C3A80")) +
  labs(x = NULL, y = "Yolcu oranı", fill = NULL,
       title = "\"Kadınlar ve çocuklar önce\" kuralının izi verilerde açıkça görünüyor") +
  theme_minimal(base_size = 11)
```



Figür 2: Cinsiyete göre hayatta kalma oranı

Fark çarpıcıdır: kadın yolcuların çoğu hayatta kalırken erkek yolcuların çoğu kalamamıştır. Bu iki grafik, 5. oturumun ana fikrini şimdiden gösteriyor: **iyi seçilmiş bir oran tablosu veya çubuk grafik, yüzlerce satırlık ham veriden daha fazla bilgi taşıyabilir.**

Sayısal Değişkenler: Merkezi Eğilim

Sayısal bir değişkenin “tipik” değerini tek bir sayıyla özetlemek istediğimizde üç aday vardır: **ortalama**, **medyan** ve **mod**. Hangisinin “doğru” olduğu, verinin şekline bağlıdır — bu yüzden önce üçünü de tanımlayıp sonra ne zaman birbirinden ayırtıklarını göreceğiz.

```
gm2007 <- gapminder |> filter(year == 2007)
nrow(gm2007)
```

```
[1] 142
```

Ortalama (aritmetik ortalama): tüm değerlerin toplamının gözlem sayısına bölümüdür.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

```
mean(gm2007$lifeExp)
```

```
[1] 67.00742
```

Medyan: veriyi küçükten büyüğe sıraladığınızda tam ortada kalan değerdir (gözlem sayısı çiftse, ortadaki iki değer ortalamasıdır). Ortalamadan farklı olarak medyan, **uç değerlerden (aşırı gözlemlerden) etkilenmez** — bu, medyanın en önemli özelliğidir.

```
median(gm2007$lifeExp)
```

```
[1] 71.9355
```

Ortalama (67) ile medyan (71.9) birbirine oldukça yakın — bu, yaşam beklentisi dağılımının aşırı uçlarda çok az ülke barındırdığı anlamına gelir. Bunu **GSYİH kişi başına** ile karşılaştıralım:

```
gm2007 |>
  summarise(ortalama = mean(gdpPercap), medyan = median(gdpPercap))
```

ortalama	medyan
11680.07	6124.371

Burada fark çok daha büyük: ortalama, medyandan belirgin şekilde yüksek. Nedeni basit — birkaç zengin ülke (Norveç, Kuveyt, ABD gibi) ortalamayı yukarı çekiyor, ama medyan bu birkaç aşırı değerden etkilenmiyor. **Gelir gibi sağa çarpık dağılımlarda medyan, “tipik ülkeyi” ortalamadan daha iyi temsil eder.** Bir siyaset bilimci için bu ayrım teknik bir ayrıntı değildir: bir ülkenin “ortalama geliri” raporlanırken hangi ölçü kullanıldığı, eşitsizlik hakkındaki anlatıyı tamamen değiştirebilir.

Mod: en sık tekrar eden değerdir. Sayısal, sürekli değişkenlerde (GSYİH gibi) genelde her değer bir kez görülür ve mod anlamsızlaşır; mod asıl kategorik ve ayrık değişkenlerde işe yarar. R’da hazır bir `mode()` fonksiyonu **yoktur** (o fonksiyon farklı bir işe yarar — değişkenin veri türünü döndürür); kendi fonksiyonumuzu yazarız:

```
mod_bul <- function(x) {
  tablo <- table(x)
  names(tablo)[tablo == max(tablo)]
}

mod_bul(titanic$embarked) # en çok hangi limandan bindiler?
```

```
[1] "S"
```

```
mod_bul(titanic$pclass) # en kalabalık sınıf
```

```
[1] "3"
```

i Hangi ölçü ne zaman kullanılır?

- **Simetrik, uç değeri az** sayısal veri → ortalama.
- **Çarpık veya uç değeri çok** sayısal veri (gelir, servet, ev fiyatı) → medyan.
- **Kategorik veya ayrık** veri → mod.

Sayısal Değişkenler: Yayılım (Değişkenlik)

İki ülkenin ortalama yaşam beklentisi aynı olabilir, ama biri bu ortalamanın etrafında çok tutarlıyken diğeri uçlarda çok farklılaşıyor olabilir. Merkezi eğilim tek başına bunu ayırt edemez — **yayılım (değişkenlik) ölçülerine** ihtiyacımız var.

Aralık (range): en basit ölçü — en büyük değer eksi en küçük değer. Tek bir aşırı değerden kolayca etkilendiği için güvenilirliği düşüktür.

```
range(gm2007$lifeExp)
```

```
[1] 39.613 82.603
```

```
diff(range(gm2007$lifeExp))
```

```
[1] 42.99
```

Çeyrekler açıklığı (IQR): veriyi dört eşit parçaya bölen çeyreklerden (Q1: %25, Q3: %75) hesaplanır; $IQR = Q3 - Q1$. Ortadaki %50'lik dilimin ne kadar geniş olduğunu gösterir ve uç değerlerden aralık kadar etkilenmez.

```
quantile(gm2007$lifeExp, probs = c(0.25, 0.5, 0.75))
```

25%	50%	75%
57.16025	71.93550	76.41325

```
IQR(gm2007$lifeExp)
```

```
[1] 19.253
```

Varyans ve standart sapma: her gözlemin ortalamadan ne kadar uzakta olduğunu, farkların karesini alıp ortalamasını hesaplayarak özetler.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad s = \sqrt{s^2}$$


Kareler alınmasının nedeni, negatif ve pozitif sapmaların birbirini götürmesini engellemektir (aksi hâlde toplam her zaman sıfıra yakın çıkardı). Standart sapma, varyansın kareköküdür ve **orijinal değişkenle aynı birimdedir** — bu yüzden yorumlaması varyanstan çok daha kolaydır.

```
gm2007 |> summarise(varyans = var(lifeExp), sd = sd(lifeExp))
```

varyans	sd
145.7578	12.07302

Standart sapma 12.1 yıl: yaşam beklentisi ülkeden ülkeye tipik olarak bu kadar farklılaşıyor demektir. Kıtalar arasında bu değişkenlik nasıl dağılıyor?

```
ggplot(gm2007, aes(x = reorder(continent, lifeExp, median), y = lifeExp)) +
  geom_boxplot(fill = "#EAF1F5", color = "#2E6E8E") +
  geom_jitter(width = 0.08, alpha = 0.35, color = "#4C3A80", size = 1.6) +
  labs(x = NULL, y = "Yaşam beklentisi (yıl)",
       title = "Afrika hem en düşük medyana hem de en geniş yayılıma sahip") +
  theme_minimal(base_size = 11)
```



Figür 3: Kıtaya göre yaşam beklentisi dağılımı (2007)

Kutu grafiği (boxplot), medyan (kutunun ortasındaki çizgi), çeyrekler açıklığı (kutunun kendisi) ve uç değerleri (noktalar) tek bir görselde birleştirir — yayılım ölçülerinin hepsini aynı anda “görmenin” en hızlı yoludur.


i Siyaset bilimci için bir yayılım ölçüsü daha: Gini katsayısı

Standart sapma bir değişkenin *ortalamadan* ne kadar saptığını ölçer; ama siyaset biliminde çoğu zaman sorulan soru budur *değildir* — asıl soru genellikle bir kaynağın (gelir, servet, toprak) popülasyon içinde **ne kadar adaletsiz dağıldığıdır**. Bunun için geliştirilmiş, 0 (tam eşitlik) ile 1 (tam eşitsizlik) arasında değişen özel bir ölçü vardır: **Gini katsayısı**. Demokrasiye geçiş ve iç çatışma yazınında, bir ülkenin gelir standardı sapmasından çok Gini katsayısı açıklayıcı değişken olarak kullanılır (*ineq* paketiyle hesaplanabilir — bu modülün kapsamı dışında, ama adını bilmekte fayda var).

Dağılımın Şekli: Çarpıklık ve Basıklık

Ortalama, medyan ve standart sapma bir dağılımı özetler ama şeklini tam anlatmaz. İki dağılımın ortalaması ve standart sapması aynı olabilir, hâlbuki biri simetrik, diğeri çarpık olabilir.

```
knitr::include_graphics(here("04_modul", "images", "carpiklik-basiklik.png"))
```



Figür 4: Çarpıklık ve basıklık tipolojisi

Çarpıklık (skewness), dağılımın hangi yöne doğru “kuyruk” uzattığını ölçer:

- **Sağa çarpık (pozitif):** uzun kuyruk sağda, çoğu gözlem solda yığılmış (gelir, servet, ev fiyatı — bir önceki bölümde GSYİH’de gördüğümüz durum). Bu durumda **ortalama > medyan**.

- **Sola çarpık (negatif):** uzun kuyruk solda. Örnek: bir sınavda çoğu öğrenci yüksek not alırken birkaç öğrencinin çok düşük not alması. Bu durumda **ortalama < medyan**.
- **Simetrik (çarpıklık ≈ 0):** ortalama ve medyan birbirine yakın.

Çarpıklığın yönünü, ortalama ile medyayı karşılaştırarak hesap yapmadan da kestirebilirsiniz — GSYİH örneğinde yaptığımız gibi.


Basıklık (kurtosis), dağılımın tepesinin ne kadar sivri, kuyruklarının ne kadar kalın olduğunu ölçer: **leptokurtik** dağılımlar sivri tepeli ve kalın kuyruklu (aşırı değer riski yüksektir — finansal getiri serilerinde sık görülür), **platikurtik** dağılımlar yayvan ve ince kuyruklu, **mezokurtik** (normal dağılım gibi) ikisinin ortasındadır. R'ın temel paketinde çarpıklık/basıklık fonksiyonu yoktur; ihtiyaç duyulduğunda **moments** veya **e1071** paketleri kullanılabilir — bu modülde kavramsal anlayış yeterlidir, hesaplama ayrıntısına girmiyoruz.

İki Değişken Arasındaki İlişki: Korelasyon

Şimdiye kadar değişkenleri tek tek özetledik. Peki iki sayısal değişken **birlikte** nasıl hareket ediyor? **Korelasyon katsayısı (Pearson's r)**, doğrusal ilişkinin yönünü ve gücünü tek bir sayıyla verir; -1 ile +1 arasında değişir.

```
ggplot(gm2007, aes(x = gdpPercap, y = lifeExp)) +
  geom_point(aes(color = continent), alpha = 0.7, size = 2) +
  scale_x_log10(labels = label_dollar()) +
  labs(x = "Kişi başı GSYİH (log ölçek)", y = "Yaşam beklentisi (yıl)",
       color = NULL,
       title = "Gelir arttıkça yaşam beklentisi de artıyor - ama ilişki doğrusal değil") +
  theme_minimal(base_size = 11)
```

Gelir arttıkça yaşam beklentisi de artıyor — ama ilişki doğrusal değil



Figür 5: GSYİH (log ölçek) ile yaşam beklentisi ilişkisi (2007)

```
cor(log(gm2007$gdpPercap), gm2007$lifeExp)
```

```
[1] 0.8089803
```

0.81 gibi güçlü bir pozitif korelasyon var (log GSYİH ile). Aynı mantıkla Titanic'te bilet ücreti ile yaş arasındaki ilişkiye bakalım:

```
cor(titanic$age, titanic$fare, use = "complete.obs")
```

```
[1] 0.1787393
```

`use = "complete.obs"` argümanına dikkat edin: `age` sütununda 263 eksik değer (NA) var (bkz. Modül 02, mantıksal indeksleme) ve `cor()` varsayılan olarak eksik değerle karşılaşınca NA döndürür; bu argüman eksik gözlemleri dışlayıp geri kalanla hesaplamaya devam eder.

⚠ Korelasyon nedensellik değildir

Zengin ülkelerde yaşam beklentisi daha yüksek — ama bu, gelirin *tek başına* uzun yaşam *sağladığı* anlamına gelmez. Sağlık altyapısı, eğitim, beslenme gibi pek çok faktör hem gelirle hem yaşam beklentisiyle birlikte hareket eder (**karıştırıcı değişkenler**). Korelasyon size yalnızca “bu ikisi birlikte hareket ediyor” der; “biri diğerine sebep oluyor” demez. Nedensellik iddiaları çok daha sıkı bir araştırma tasarımı gerektirir — bu, dönem sonuna doğru regresyon modülünde tekrar karşımıza çıkacak bir tema.

Yukarıdaki gelir–yaşam beklentisi örneğinde gerçek bir mekanizma (karıştırıcı değişken) vardı — sağlık altyapısı ikisini de etkiliyor. Ama bazen iki değişken arasında **hiçbir** mekanizma olmadan, salt tesadüfen yüksek bir korelasyon çıkabilir. Harvard’dan istatistikçi Tyler Vigen’in *Spurious Correlations* (Sahte Korelasyonlar) projesinden ünlü bir örnek: 1999–2009 arasında, **Nicolas Cage’in o yıl oynadığı film sayısı ile o yıl yüzme havuzuna düşerek boğulan kişi sayısı arasındaki korelasyon $r \approx 0,666$ ’dır** — güçlü bir ilişki, ama aralarında ne bir mekanizma ne de ortak bir karıştırıcı değişken vardır; yalnızca 11 yıllık kısa bir seride rastlanan bir tesadüftür. Bu ayrım önemlidir: düşük bir p-değeri veya yüksek bir korelasyon, ilişkinin *anlamlı* olduğunu garanti etmez — özellikle az sayıda gözlemle çalışırken.

Eksik Veri: Kendisi de Bir Bulgudur

Modül 02’de NA (bilinmeyen değer) kavramını görmüştük. Tanımlayıcı istatistik hesaplarken `na.rm = TRUE` yazıp eksik gözlemleri sessizce dışarıda bırakmak cazip gelir — ama bu bir araştırma kararıdır, teknik bir ayrıntı değildir.

```
mean(is.na(titanic$age))
```

```
[1] 0.2009167
```

Yolcuların yaklaşık %20’sinin yaşı bilinmiyor. Sorulması gereken soru şudur: **bu eksiklik rastgele mi, yoksa bir örüntü mü izliyor?**

```
titanic |>
  group_by(pclass) |>
  summarise(eksik_yas_orani = round(mean(is.na(age)), 3))
```

pclass	eksik_yas_orani
1	0.121

pclass	eksik_yas_orani
2	0.058
3	0.293

Rastgele değil: 3. sınıfta yaşı bilinmeyen yolcu oranı (%29), 1. sınıftakinden (%12) belirgin şekilde yüksek. Muhtemel açıklama, 3. sınıf yolcuların büyük kısmının kayıt tutulması daha zayıf olan göçmen yolcular olmasıdır. Bunun sonucu somuttur: `mean(age, na.rm = TRUE)` hesapladığınızda, örneklemden **orantısız biçimde daha fazla yoksul ve genç göçmen** düşmüş olur — bulacağınız “ortalama yaş” tüm gemiyi değil, kaydı daha iyi tutulan, görece daha varlıklı bir alt kümeyi temsil eder. Sosyal bilimlerde eksik veri nadiren tamamen rastgeledir (bkz. anket araştırmalarında hane geliri veya oy tercihi soruları); eksiklik oranının kendisi, raporlanması gereken bir tanımlayıcı istatistiktir.

Araştırmacının Alet Çantası: gtsummary ile “Tablo 1”

Şimdiye kadar özet istatistikleri dplyr çıktısı olarak, konsol formatında gördük. Ama hemen hemen her ampirik makale, tez veya raporun ilk sayfasında bir **“Tablo 1: Betimsel İstatistikler”** bulunur — örnekleme grup grup (burada: hayatta kalma durumuna göre) özetleyen, yayına hazır bir tablo. Bunu Word’de elle kurmak saatler alır; gtsummary paketi tek bir çağrıda üretir.

```
library(gtsummary)

titanic |>
  mutate(durum = factor(survived, labels = c("Kaybedildi", "Hayatta kaldı"))) |>
  select(pclass, sex, age, fare, durum) |>
  tbl_summary(
    by = durum,
    statistic = list(all_continuous() ~ "{mean} ({sd})",
                     all_categorical() ~ "{n} ({p}%)",
    missing_text = "Eksik veri",
    label = list(pclass ~ "Yolcu sınıfı", sex ~ "Cinsiyet",
                  age ~ "Yaş", fare ~ "Bilet ücreti")
  ) |>
  add_p() |>
  modify_header(label = "**Değişken**", p.value = "**p-değeri**") |>
  modify_spanning_header(all_stat_cols() ~ "**Hayatta kalma durumu**")
```

`add_p()`, her satır için grup farkının istatistiksel olarak anlamlı olup olmadığını otomatik test eder (kategorik değişkende ki-kare, sayısal değişkende Wilcoxon) — bu testlerin **kendisini** 9.

Tablo 6

Değişken	Hayatta kalma durumu		p-değeri ²
	Kaybedildi N = 809 ¹	Hayatta kaldı N = 500 ¹	
Yolcu sınıfı			<0.001
1	123 (15%)	200 (40%)	
2	158 (20%)	119 (24%)	
3	528 (65%)	181 (36%)	
Cinsiyet			<0.001
female	127 (16%)	339 (68%)	
male	682 (84%)	161 (32%)	
Yaş	31 (14)	29 (15)	0.2
Eksik veri	190	73	
Bilet ücreti	23 (34)	49 (69)	<0.001
Eksik veri	1	0	

¹n (%); Mean (SD)

²Pearson's Chi-squared test; Wilcoxon rank sum test

oturumda göreceğiz; şimdilik yalnızca çıktının ne anlama geldiğini bilmeniz yeterli. Bu tek kod bloğu, R'ın Excel veya SPSS'e göre neden bu kadar zaman kazandırdığının somut bir örneğidir.

Özet

- **Merkezi eğilim:** ortalama (`mean()`), medyan (`median()`), mod (elle yazılan fonksiyon). Çarpık veride medyan daha güvenilirdir.
- **Yayılım:** aralık (`range()`), çeyrekler açıklığı (`IQR()`), varyans (`var()`), standart sapma (`sd()`).
- **Şekil:** çarpıklık (yön) ve basıklık (tepe/kuyruk kalınlığı) — kavramsal düzeyde.
- **İlişki:** korelasyon (`cor()`) doğrusal ilişkinin yönünü ve gücünü özetler; **nedensellik iddia etmez**.
- Kategorik değişkenler için: `count()`, çapraz tablolar, `geom_bar(position = "fill")` ile oranların görselleştirilmesi.
- **Eksik veri** kendi başına bir bulgudur — eksiklik oranı ve örüntüsü rapor edilmeden `na.rm = TRUE` ile geçilmemelidir.
- `gtsummary::tbl_summary()`, akademik yayınların standart “Tablo 1”ini tek çağrıda üretir.

Bir sonraki modülde bu araçları rastgele değişkenler ve olasılık dağılımlarıyla birleştirerek, örneklemden popülasyona nasıl çıkarım yapılacağının temelini atacacağız.