

Modül 04: Tanımlayıcı İstatistik

Prof. Dr. Hakan Mehmetcik

2026-09-10

Tanımlayıcı İstatistik Nedir?

Bir veri setinde binlerce, hatta milyonlarca gözlem olabilir. 3. modülde `gapminder` veri setinin 1704 satırını tek tek okuyarak “dünya nasıl değişti?” sorusuna cevap veremezsiniz — göze çarpan bir grafiğe ya da birkaç sayıya ihtiyacınız vardır. **Tanımlayıcı (betimsel) istatistik**, tam olarak bunu yapar: bir değişkenin dağılımını, merkezini ve yayılımını az sayıda özet sayı veya tabloyla anlatılır kılar.

Bunu iki ailede ele alacağız:

1. **Kategorik değişkenler** için: frekans tabloları ve oranlar.
2. **Sayısal değişkenler** için: merkezi eğilim (ortalama, medyan, mod), yayılım (varyans, standart sapma, çeyrekler açıklığı) ve dağılımın şekli (çarpıklık, basıklık).

Sonda, iki sayısal değişken arasındaki ilişkiyi özetleyen bir ölçüye —korelasyona— de değineceğiz; ama bunun bir *nedensellik* iddiası olmadığını en baştan vurgulayalım.

Bu modülde iki veri seti kullanacağız: `gapminder` (3. modülden tanıdık — ülke, yıl, yaşam beklentisi, GSYİH), ve **Titanic yolcu listesi** (1309 yolcunun sınıfı, cinsiyeti, yaşı, bileti ve hayatta kalıp kalmadığı) — `data/titanic.csv` içinde, projeye yerel olarak dahil edilmiştir.

```
titanic <- read.csv(here("data", "titanic.csv"))
str(titanic[, c("pclass", "survived", "sex", "age", "fare", "embarked")])
```

```
'data.frame':  1309 obs. of  6 variables:
 $ pclass   : int  1 1 1 1 1 1 1 1 1 1 ...
 $ survived: int  1 1 0 0 0 1 1 0 1 0 ...
 $ sex      : chr  "female" "male" "female" "male" ...
 $ age      : num  29 0.917 2 30 25 ...
 $ fare     : num  211 152 152 152 152 ...
 $ embarked: chr   "S" "S" "S" "S" ...
```

Kategorik Değişkenler: Frekans ve Oran

Kategorik bir değişken için ilk soru her zaman aynıdır: **hangi kategoriden kaç tane var?** `dplyr::count()` bunu tek satırda verir.

```
titanic |>
  count(pclass, name = "n") |>
  mutate(oran = round(n / sum(n), 3))
```

pclass	n	oran
1	323	0.247
2	277	0.212
3	709	0.542

Yolcuların yaklaşık %54'ü 3. sınıfta seyahat ediyordu — Titanic'in sosyal kompozisyonu hakkında tek bir sayı bile fikir veriyor. Ama asıl ilgi çekici soru şu: **hayatta kalma sınıfa göre değişiyor muydu?** Bunun için iki kategorik değişkeni birlikte özetleyen bir **çapraz tablo** (kontenjans tablosu) kurarız.

```
titanic |>
  count(pclass, survived) |>
  group_by(pclass) |>
  mutate(oran = round(n / sum(n), 3)) |>
  ungroup()
```

pclass	survived	n	oran
1	0	123	0.381
1	1	200	0.619
2	0	158	0.570
2	1	119	0.430
3	0	528	0.745
3	1	181	0.255


Sayılar tek başına ikna edici değildir; bir çubuk grafik örüntüyü göz kırpmadan gösterir.

```
titanic |>
  mutate(
    sinif = factor(pclass, labels = c("1. sınıf", "2. sınıf", "3. sınıf")),
```

```

durum = factor(survived, labels = c("Kaybedildi", "Hayatta kaldı"))
) |>
ggplot(aes(x = sinif, fill = durum)) +
geom_bar(position = "fill") +
scale_y_continuous(labels = label_percent()) +
scale_fill_manual(values = c("Kaybedildi" = "#8C8C8C", "Hayatta kaldı" = "#4C3A80")) +
labs(x = NULL, y = "Yolcu oranı", fill = NULL,
     title = "1. sınıf yolcunun hayatta kalma şansı 3. sınıftan çok daha yüksekti") +
theme_minimal(base_size = 11)

```



Figür 1: Yolcu sınıfına göre hayatta kalma oranı


`position = "fill"` her çubuğu %100'e tamamlar; böylece mutlak yolcu sayısı değil, **oran** karşılaştırılır — 1. sınıfta çok daha az yolcu olmasına rağmen (216'ya karşı 709), grafik hâlâ adil bir karşılaştırma sunar. Aynı mantık cinsiyet için de geçerlidir:

```

titanic |>
mutate(durum = factor(survived, labels = c("Kaybedildi", "Hayatta kaldı"))) |>
ggplot(aes(x = sex, fill = durum)) +
geom_bar(position = "fill") +
scale_y_continuous(labels = label_percent()) +

```

```
scale_fill_manual(values = c("Kaybedildi" = "#8C8C8C", "Hayatta kaldı" = "#4C3A80")) +
labs(x = NULL, y = "Yolcu oranı", fill = NULL,
     title = "\"Kadınlar ve çocuklar önce\" kuralının izi verilerde açıkça görünüyor") +
theme_minimal(base_size = 11)
```



Figür 2: Cinsiyete göre hayatta kalma oranı

Fark çarpıcıdır: kadın yolcuların çoğu hayatta kalırken erkek yolcuların çoğu kalamamıştır. Bu iki grafik, 5. oturumun ana fikrini şimdiden gösteriyor: **iyi seçilmiş bir oran tablosu veya çubuk grafik, yüzlerce satırlık ham veriden daha fazla bilgi taşıyabilir.**

Sayısal Değişkenler: Merkezi Eğilim

Sayısal bir değişkenin “tipik” değerini tek bir sayıyla özetlemek istediğimizde üç aday vardır: **ortalama**, **medyan** ve **mod**. Hangisinin “doğru” olduğu, verinin şekline bağlıdır — bu yüzden önce üçünü de tanımlayıp sonra ne zaman birbirinden ayırtıklarını göreceğiz.

```
gm2007 <- gapminder |> filter(year == 2007)
nrow(gm2007)
```

[1] 142

Ortalama (aritmetik ortalama): tüm değerlerin toplamının gözlem sayısına bölümüdür.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

```
mean(gm2007$lifeExp)
```

[1] 67.00742

Medyan: veriyi küçükten büyüğe sıraladığınızda tam ortada kalan değerdir (gözlem sayısı çiftse, ortadaki iki değer ortalama ortalamasıdır). Ortalamadan farklı olarak medyan, **uç değerlerden (aşırı gözlemlerden) etkilenmez** — bu, medyanın en önemli özelliğidir.

```
median(gm2007$lifeExp)
```

[1] 71.9355

Ortalama (67) ile medyan (71.9) birbirine oldukça yakın — bu, yaşam beklentisi dağılımının aşırı uçlarda çok az ülke barındırdığı anlamına gelir. Bunu **GSYİH kişi başına** ile karşılaştıralım:

```
gm2007 |>
  summarise(ortalama = mean(gdpPercap), medyan = median(gdpPercap))
```

ortalama	medyan
11680.07	6124.371

Burada fark çok daha büyük: ortalama, medyandan belirgin şekilde yüksek. Nedeni basit — birkaç zengin ülke (Norveç, Kuveyt, ABD gibi) ortalamaı yukarı çekiyor, ama medyan bu birkaç aşırı değerden etkilenmiyor. **Gelir gibi sağa çarpık dağılımlarda medyan, “tipik ülkeyi” ortalamadan daha iyi temsil eder.** Bir siyaset bilimci için bu ayrım teknik bir ayrıntı değildir: bir ülkenin “ortalama geliri” raporlanırken hangi ölçü kullanıldığı, eşitsizlik hakkındaki anlatıyı tamamen değiştirebilir.

Mod: en sık tekrar eden değerdir. Sayısal, sürekli değişkenlerde (GSYİH gibi) genelde her değer bir kez görülür ve mod anlamsızlaşır; mod asıl kategorik ve ayrık değişkenlerde işe yarar. R’da hazır bir `mode()` fonksiyonu **yoktur** (o fonksiyon farklı bir işe yarar — değişkenin veri türünü döndürür); kendi fonksiyonumuzu yazarız:

```
mod_bul <- function(x) {  
  tablo <- table(x)  
  names(tablo)[tablo == max(tablo)]  
}  
  
mod_bul(titanic$embarked) # en çok hangi limandan bindiler?
```

```
[1] "S"
```

```
mod_bul(titanic$pclass) # en kalabalık sınıf
```

```
[1] "3"
```

i Hangi ölçü ne zaman kullanılır?

- **Simetrik, uç değeri az** sayısal veri → ortalama.
- **Çarpık veya uç değeri çok** sayısal veri (gelir, servet, ev fiyatı) → medyan.
- **Kategorik veya ayırık** veri → mod.

Sayısal Değişkenler: Yayılım (Değişkenlik)

İki ülkenin ortalama yaşam beklentisi aynı olabilir, ama biri bu ortalamanın etrafında çok tutarlıyken diğeri uçlarda çok farklılaşıyor olabilir. Merkezi eğilim tek başına bunu ayırt edemez — **yayılım (değişkenlik) ölçülerine** ihtiyacımız var.

Aralık (range): en basit ölçü — en büyük değer eksi en küçük değer. Tek bir aşırı değerden kolayca etkilendiği için güvenilirliği düşüktür.

```
range(gm2007$lifeExp)
```

```
[1] 39.613 82.603
```

```
diff(range(gm2007$lifeExp))
```

```
[1] 42.99
```

Çeyrekler açıklığı (IQR): veriyi dört eşit parçaya bölen çeyreklerden (Q1: %25, Q3: %75) hesaplanır; $IQR = Q3 - Q1$. Ortadaki %50'lik dilimin ne kadar geniş olduğunu gösterir ve uç değerlerden aralık kadar etkilenmez.

```
quantile(gm2007$lifeExp, probs = c(0.25, 0.5, 0.75))
```

25%	50%	75%
57.16025	71.93550	76.41325

```
IQR(gm2007$lifeExp)
```

```
[1] 19.253
```

Varyans ve standart sapma: her gözlemin ortalamadan ne kadar uzakta olduğunu, farkların karesini alıp ortalamasını hesaplayarak özetler.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad s = \sqrt{s^2}$$


Kareler alınmasının nedeni, negatif ve pozitif sapmaların birbirini götürmesini engellemektir (aksi hâlde toplam her zaman sıfıra yakın çıkardı). Standart sapma, varyansın kareköküdür ve **orijinal değişkenle aynı birimdedir** — bu yüzden yorumlaması varyanstan çok daha kolaydır.

```
gm2007 |>
  summarise(varyans = var(lifeExp), sd = sd(lifeExp))
```

varyans	sd
145.7578	12.07302

Standart sapma 12.1 yıl: yaşam beklentisi ülkeden ülkeye tipik olarak bu kadar farklılaşıyor demektir. Kıtalar arasında bu değişkenlik nasıl dağılıyor?

```
ggplot(gm2007, aes(x = reorder(continent, lifeExp, median), y = lifeExp)) +
  geom_boxplot(fill = "#EAF1F5", color = "#2E6E8E") +
  geom_jitter(width = 0.08, alpha = 0.35, color = "#4C3A80", size = 1.6) +
  labs(x = NULL, y = "Yaşam beklentisi (yıl)",
       title = "Afrika hem en düşük medyana hem de en geniş yayılıma sahip") +
  theme_minimal(base_size = 11)
```



Figür 3: Kıtaya göre yaşam beklentisi dağılımı (2007)


Kutu grafiği (boxplot), medyan (kutunun ortasındaki çizgi), çeyrekler açıklığı (kutunun kendisi) ve uç değerleri (noktalar) tek bir görselde birleştirir — yayılım ölçülerinin hepsini aynı anda “görmenin” en hızlı yoludur.

Dağılımın Şekli: Çarpıklık ve Basıklık

Ortalama, medyan ve standart sapma bir dağılımı özetler ama şeklini tam anlatmaz. İki dağılımın ortalaması ve standart sapması aynı olabilir, hâlbuki biri simetrik, diğeri çarpık olabilir.

```
knitr::include_graphics(here("04_modul", "images", "carpiklik-basiklik.png"))
```

Dağılımın Şekli: Çarpıklık ve Basıklık



Figür 4: Çarpıklık ve basıklık tipolojisi

Çarpıklık (skewness), dağılımın hangi yöne doğru “kuyruk” uzattığını ölçer:

- **Sağa çarpık (pozitif):** uzun kuyruk sağda, çoğu gözlem solda yığılmış (gelir, servet, ev fiyatı — bir önceki bölümde GSYİH’de gördüğümüz durum). Bu durumda **ortalama > medyan**.
- **Sola çarpık (negatif):** uzun kuyruk solda. Örnek: bir sınavda çoğu öğrenci yüksek not alırken birkaç öğrencinin çok düşük not alması. Bu durumda **ortalama < medyan**.
- **Simetrik (çarpıklık = 0):** ortalama ve medyan birbirine yakın.


Çarpıklığın yönünü, ortalama ile medyanyı karşılaştırarak hesap yapmadan da kestirebilirsiniz — GSYİH örneğinde yaptığımız gibi.

Basıklık (kurtosis), dağılımın tepesinin ne kadar sivri, kuyruklarının ne kadar kalın olduğunu ölçer: **leptokurtik** dağılımlar sivri tepeli ve kalın kuyruklu (aşırı değer riski yüksektir — finansal getiri serilerinde sık görülür), **platikurtik** dağılımlar yayvan ve ince kuyruklu, **mezokurtik** (normal dağılım gibi) ikisinin ortasındadır. R’in temel paketinde çarpıklık/basıklık fonksiyonu yoktur; ihtiyaç duyulduğunda **moments** veya **e1071** paketleri kullanılabilir — bu modülde kavramsal anlayış yeterlidir, hesaplama ayrıntısına girmiyoruz.

İki Değişken Arasındaki İlişki: Korelasyon

Şimdiye kadar değişkenleri tek tek özetledik. Peki iki sayısal değişken **birlikte** nasıl hareket ediyor? **Korelasyon katsayısı (Pearson’s r)**, doğrusal ilişkinin yönünü ve gücünü tek bir sayıyla verir; -1 ile +1 arasında değişir.

```
ggplot(gm2007, aes(x = gdpPercap, y = lifeExp)) +
  geom_point(aes(color = continent), alpha = 0.7, size = 2) +
  scale_x_log10(labels = label_dollar()) +
  labs(x = "Kişi başı GSYİH (log ölçek)", y = "Yaşam beklentisi (yıl)",
       color = NULL,
       title = "Gelir arttıkça yaşam beklentisi de artıyor - ama ilişki doğrusal değil") +
  theme_minimal(base_size = 11)
```



```
cor(log(gm2007$gdpPercap), gm2007$lifeExp)
```

```
[1] 0.8089803
```

0.81 gibi güçlü bir pozitif korelasyon var (log GSYİH ile). Aynı mantıkla Titanic'te bilet ücreti ile yaş arasındaki ilişkiye bakalım:

```
cor(titanic$age, titanic$fare, use = "complete.obs")
```

```
[1] 0.1787393
```

`use = "complete.obs"` argümanına dikkat edin: `age` sütununda 263 eksik değer (`NA`) var (bkz. Modül 02, mantıksal indeksleme) ve `cor()` varsayılan olarak eksik değerle karşılaşınca `NA` döndürür; bu argüman eksik gözlemleri dışlayıp geri kalanla hesaplamaya devam eder.

⚠ Korelasyon nedensellik değildir

Zengin ülkelerde yaşam beklentisi daha yüksek — ama bu, gelirin *tek başına* uzun yaşam *sağladığı* anlamına gelmez. Sağlık altyapısı, eğitim, beslenme gibi pek çok faktör hem gelirle hem yaşam beklentisiyle birlikte hareket eder (**karıştırıcı değişkenler**). Korelasyon size yalnızca “bu ikisi birlikte hareket ediyor” der; “biri diğerine sebep oluyor” demez. Nedensellik iddiaları çok daha sıkı bir araştırma tasarımı gerektirir — bu, dönem sonuna doğru regresyon modülünde tekrar karşınıza çıkacak bir tema.

Özet

- **Merkezi eğilim:** ortalama (`mean()`), medyan (`median()`), mod (elle yazılan fonksiyon). Çarpık veride medyan daha güvenilirdir.
- **Yayılım:** aralık (`range()`), çeyrekler açıklığı (`IQR()`), varyans (`var()`), standart sapma (`sd()`).
- **Şekil:** çarpıklık (yön) ve basıklık (tepe/kuyruk kalınlığı) — kavramsal düzeyde.
- **İlişki:** korelasyon (`cor()`) doğrusal ilişkinin yönünü ve gücünü özetler; **nedensellik iddia etmez**.
- Kategorik değişkenler için: `count()`, çapraz tablolar, `geom_bar(position = "fill")` ile oranların görselleştirilmesi.

Bir sonraki modülde bu araçları rastgele değişkenler ve olasılık dağılımlarıyla birleştirerek, örneklemiden popülasyona nasıl çıkarım yapılacağını temelinizi atacağız.