

Modül 06: Çıkarımsal İstatistiğe Giriş


Prof. Dr. Hakan Mehmetcik

2026-09-11

Tanımlayıcıdan Çıkarımsala

Modül 04'te tek bir örnekleme özetlemeyi öğrendiniz: **gapminder**'daki 142 ülkenin yaşam beklentisi ortalamasını, kişi başı GSYİH'nin medyanını, kıtalar arası korelasyonu hesapladınız. Bu **tanımlayıcı istatistiktir** — elinizdeki veriyi özetler, ondan öteye geçmez.

Ama araştırmacı olarak asıl sorduğunuz soru nadiren “bu 142 ülkede ne oldu?” sorusudur. Genelde şunu sorarsınız: *gelecek yıl* ne olur? *Elimde olmayan* ülkeler için de geçerli mi? Bu örneklemden yola çıkarak *daha geniş bir evren* hakkında ne söyleyebilirim? Bu sorulara cevap veren araç **çıkarımsal istatistiktir**.



Çıkarımsal istatistik, daha küçük bir gruptan (**örneklem**) elde edilen verilerle daha büyük bir grup (**popülasyon**) hakkında çıkarımlarda bulunmayı içerir. Bunun gerekli olmasının nedeni basit: popülasyondaki her birimden veri toplamak çoğu zaman ya imkânsız ya da gereksiz maliyetlidir.

Popülasyon ve Örneklem: Bir Düşünce Deneyi

gapminder, dünyadaki neredeyse tüm ülkeleri kapsadığı için popülasyon ile örneklem arasındaki farkı hissetmek zor olabilir. Bunu somutlaştırmak için 2007 kesitinden **rastgele 20 ülkelik bir örneklem** çekelim ve sanki elimizde yalnızca bu 20 ülke varmış gibi düşünelim:

```
set.seed(2026)
ornek_20 <- gapminder |>
  filter(year == 2007) |>
  slice_sample(n = 20)

ornek_20 |> select(country, continent, lifeExp) |> arrange(desc(lifeExp))
```

country	continent	lifeExp
Iceland	Europe	81.757
France	Europe	80.657
Netherlands	Europe	79.762
Belgium	Europe	79.441
Finland	Europe	79.313
Ecuador	Americas	74.994
Malaysia	Asia	74.241
Venezuela	Americas	73.747
Nicaragua	Americas	72.899
Saudi Arabia	Asia	72.777
Pakistan	Asia	65.483
Senegal	Africa	63.062
Myanmar	Asia	62.069
Haiti	Americas	60.916
Sudan	Africa	58.556
Uganda	Africa	51.542
Burundi	Africa	49.580
Cote d'Ivoire	Africa	48.328
Rwanda	Africa	46.242
Sierra Leone	Africa	42.568

```
populasyon_2007 <- gapminder |> filter(year == 2007)

data.frame(
  grup = c("Örneklem (n = 20)", "Popülasyon (N = 142)"),
  ort_yasam_beklentisi = c(mean(ornek_20$lifeExp), mean(populasyon_2007$lifeExp))
)
```

grup	ort_yasam_beklentisi
Örneklem (n = 20)	65.89670
Popülasyon (N = 142)	67.00742

İki ortalama birbirine yakın ama **aynı değil**. Bu fark, tesadüfen hangi 20 ülkeyi çektiğimizden kaynaklanır — buna **örnekleme hatası** denir. Çıkarımsal istatistiğin temel sorusu tam olarak budur: elimdeki örneklem ortalaması, gerçek popülasyon ortalamasından *ne kadar* sapabilir, ve bu sapmayı hesaba katarak nasıl güvenilir bir sonuç çıkarabilirim?

Neden `set.seed()`?

`slice_sample()` her çalıştırıldığında farklı bir rastgele örneklem seçer. `set.seed(2026)` bu rastgeleliği **sabitler**: aynı kodu siz de çalıştırdığınızda birebir aynı 20 ülkeyi elde edersiniz. Bilimsel yeniden üretilebilirliğin R'daki karşılığı budur.

İleri düzey (sınav kapsamı dışı): Teorik popülasyon nedir?


Akla şu soru gelebilir: “*gapminder* zaten dünyadaki neredeyse tüm ülkeleri içeriyor — elimizde popülasyonun tamamı varken neden hâlâ çıkarım yapıyoruz?”

Cevap, “popülasyon”u nasıl tanımladığımızla ilgili. Bugün var olan ülkeler kümesi — sınırları, tarihi, siyasi rejimleriyle — savaşlar, antlaşmalar ve tesadüflerin ürünü olan **tek bir tarihsel senaryodur**. Çıkarımsal istatistik, gözlemlediğimiz bu tek senaryoyu, mümkün olan sonsuz sayıda alternatif senaryonun (**teorik popülasyon** ya da **veri üreten mekanizma**, DGP) bir örnekleme gibi ele alır. Sorumuz artık yalnızca “bilmediğimiz ülkeleri tahmin edebilir miyiz” değil, “gözlemlediğimiz bir ilişki (ör. demokrasi ile barış arasındaki ilişki) *rastgele bir tesadüf mü*, yoksa *sistematiik bir mekanizmanın ürünü mü*” sorusudur. Bu fikre **8.–9. oturumlarda**, hipotez testinin mantığını kurarken tekrar döneceğiz.

Çıkarımsal İstatistiğin Dört Sütunu

Çıkarımsal istatistik dört ana alana ayrılır. Dönemin geri kalanı (7.–11. oturumlar) bu dört sütunu sırayla, hep aynı **gapminder** zemininde işleyecek.


Çıkarımsal İstatistiğin Dört Sütunu



Örnekleme (Sampling)

Popülasyonun tamamı yerine, onu temsil edecek küçük bir grup seçme sürecidir. Örneklem *rastgele* ve *yeterince büyük* olduğunda, popülasyonu makul bir yaklaşıklıkla yansıtır — yukarıdaki 20 ülkelik örneklemin ortalamasının popülasyon ortalamasına yakın çıkması tesadüf değildi. Bu konuyu **7. oturumda** (07_modul/), örneklem dağılımı ve Merkezi Limit Teoremi ile birlikte derinleştireceğiz.

Örnekleme Süreci Döngüsü




Tahmin (Estimation)

Örnekleme verisini kullanarak popülasyonun bilinmeyen bir parametresini öngörmektir. İki türü vardır:

- **Nokta tahmini:** tek bir sayı (örneğin, yukarıdaki örneklemin ortalaması, 65.9 yıl).
- **Aralık tahmini:** parametrenin belirli bir **güven aralığı** içinde olduğunu belirtir (“popülasyon ortalaması %95 güvenle X ile Y yılı arasındadır” gibi).

Güven aralıklarını **telafi oturumunda** (09_modul/) hesaplayacağız.




İstatistikte tahmin yöntemlerini karşılaştırma.

Hipotez Testi (Hypothesis Testing)

Örneklem verisine dayanarak popülasyon hakkında bir iddiayı test etme sürecidir. Örneğin: “Avrupa ülkelerinin ortalama yaşam beklentisi, Asya ülkelerinininkinden farklıdır” iddiasını, elimizdeki örneklemin bu farkı destekleyip desteklemediğine bakarak değerlendiririz. Bunu **8. ve 9. oturumlarda** (10_modül/) t-testi, ki-kare ve ANOVA ile işleyeceğiz.

Hipotez Testi Süreci

Örnek Veri Toplama



Hipotezleri Formüle Et


Verileri Analiz Et

Kanıtı Değerlendir

Hipotezler Üzerine Karar

Regresyon / Modelleme

Değişkenler arasındaki ilişkiyi sayısal olarak ifade edip, bir sonuç değişkenini (bağımlı değişken) tahmin etmeye yarar. Bu derste **üç** regresyon türünü işleyeceğiz:



! Kapsam sınırı

Regresyon ve modelleme literatürü çok geniştir (zaman serisi, panel veri modelleri, karar ağaçları, yapay sinir ağları gibi onlarca yöntem içerir). **Bu ders yalnızca yukarıdaki üç yöntemi** —doğrusal, çoklu ve lojistik regresyonu— kapsar; bunlar **10. ve 11. oturumlarda** (11_modul/, 12_modul/, 13_modul/) işlenecektir. Diğer yöntemler bu dersin kapsamı dışındadır.

Bu Yolculuğun İlk Durağı: Olasılık

Yukarıdaki dört sütunun hepsi, ortak bir temel üzerine kuruludur: **olasılık**. Bir örneklem ortalamasının popülasyon ortalamasından ne kadar sapabileceğini konuşabilmemiz için önce “sapma” kavramını sayısallaştırmamız, yani **rastgele değişkenler** ve **olasılık dağılımlarıyla** çalışmayı öğrenmemiz gerekiyor. Bir sonraki belgede (06_modul_ders_olasilik.qmd) tam olarak buna bakacağız.

Özet

Not

Bu belgede öğrendikleriniz

- Tanımlayıcı istatistik (veriyi özetler) ile çıkarımsal istatistik (veriden popülasyona genelleme yapar) arasındaki fark
- **Popülasyon** ve **örneklem** kavramları; `slice_sample()` ile rastgele örneklem çekmek
- **Örnekleme hatası**: örneklem istatistiğinin popülasyon parametresinden sapması
- `set.seed()` ile rastgeleliği sabitleyip yeniden üretilebilirlik sağlamak
- Çıkarımsal istatistiğin dört sütunu: örnekleme, tahmin, hipotez testi, regresyon/modelleme — ve her birinin dönem içindeki yeri
- Bu dersin regresyon kapsamının doğrusal, çoklu ve lojistik regresyonla sınırlı olduğu

Sırada Ne Var?

Dört sütunun ortak temeli olan **olasılığa** geçiyoruz (`06_modul_ders_olasilik.qmd`): rastgele değişkenler, olasılık dağılımları ve bunları R’da nasıl hesaplayacağımız. Ardından **3. oturumda** bu modülle birlikte işlenen Quarto ile raporlama konusuna (`06_modul_ders_quarto.qmd`), **7. oturumda** ise örnekleme dağılımı ve Merkezi Limit Teoremi’ne geçeceğiz.