

Modül 06: Olasılık, Rastgele Değişkenler ve Dağılımlar

Prof. Dr. Hakan Mehmetcik

2026-09-11

Olasılık Nedir?

Olasılık, bir olayın gerçekleşme ihtimalini 0 ile 1 arasında bir sayıyla ifade eder: 0 “kesinlikle gerçekleşmez”, 1 “kesinlikle gerçekleşir”, 0.5 ise “gerçekleşme ve gerçekleşmeme ihtimali eşit” demektir. Bir madeni parayı attığınızda yazı gelme olasılığı 0.5’tir — bu sezgi herkese tamdır ve olasılığın “adil” bir örneklem uzayında ne anlama geldiğini gösterir.

Bu derste bu sezgiyi zar ve para örneklerinde bırakmayıp, kursun başından beri kullandığımız **gapminder** verisine taşıyacağız. Amaç yalnızca formülleri elle hesaplamak değil, **R’ın olasılık ve dağılım fonksiyonlarını** kullanmayı öğrenmektir.

Klasik ve Deneysel Olasılık

Klasik (teorik) olasılık, örneklem uzayındaki tüm sonuçların eşit olası olduğu varsayımıyla doğrudan hesaplanır:

$$P(\text{olay}) = \frac{\text{istenen sonuç sayısı}}{\text{olası tüm sonuç sayısı}}$$

gapminder’da 1704 ülke-yıl gözlemi var. Rastgele birini seçersem, Afrika kıtasından olma olasılığı nedir?

```
teorik_p <- mean(gapminder$continent == "Africa")
teorik_p
```

```
[1] 0.3661972
```


`mean()` burada bir kısayol: `continent == "Africa"` her gözlem için TRUE/FALSE üretir, ortalaması ise “kaçta kaçının doğru olduğu”, yani tam olarak klasik olasılık formülüdür.

Deneysel (ampirik) olasılık ise bir deneyi çok sayıda tekrarlayıp, istenen sonucun görülme *sıklığına* bakar. Deneme sayısı arttıkça deneysel olasılık teorik değere yaklaşır — buna **Büyük Sayılar Kanunu** denir. Bunu R’da `sample()` ile simüle edelim:

```
set.seed(2026)
buyuklukler <- c(10, 50, 100, 500, 1000, 5000, 10000)
deneysel_p <- sapply(buyuklukler, function(n) {
  ornek <- sample(gapminder$continent, size = n, replace = TRUE)
  mean(ornek == "Africa")
})
data.frame(orneklem_buyuklugu = buyuklukler, deneysel_olasilik = round(deneysel_p, 3))
```

orneklem_buyuklugu	deneysel_olasilik
10	0.200
50	0.340
100	0.420
500	0.410
1000	0.345
5000	0.367
10000	0.366

```
ggplot(data.frame(n = buyuklukler, p = deneysel_p), aes(n, p)) +
  geom_line(color = "#2E6E8E") +
  geom_point(color = "#2E6E8E", size = 2) +
  geom_hline(yintercept = teorik_p, linetype = "dashed", color = "firebrick") +
  scale_x_log10() +
  labs(x = "Örneklem büyüklüğü (log ölçek)", y = "Deneysel olasılık (Afrika)") +
  theme_minimal()
```



Figür 1: DeneySEL olasılık, örneklem büyüdükçe teorik değere yakınsar

Kesikli çizgi teorik değeri (0.366) gösteriyor; mavi nokta dizisi örneklem büyüdükçe ona yaklaşıyor. `sample(..., replace = TRUE)`'daki `replace = TRUE` argümanına dikkat edin: her çekilişten sonra gözlemi “geri koyuyoruz”, böylece her deneme birbirinden **bağımsız** kalıyor. Bağımsızlığın neden önemli olduğuna birazdan döneceğiz.

Temel Kavramlar

1. **Deney**: sonucu belirsiz herhangi bir işlem. `gapminder`'dan rastgele bir ülke-yıl gözlemi seçmek bir deneydir.
2. **Örneklem uzayı**: tüm olası sonuçların kümesi. Kıta değişkeni için örneklem uzayı Africa, Americas, Asia, Europe, Oceania şeklindeki 5 kategoridir.
3. **Olay**: örneklem uzayının bir alt kümesi. Örneğin, “seçilen gözlemin yaşam beklentisinin 70'in üzerinde olması” bir olaydır.
4. **Bağımsız olaylar**: birinin sonucu diğerini etkilemez. Yukarıdaki simülasyonda `replace = TRUE` kullanmamızın nedeni buydu.

5. **Bağımlı olaylar:** birinin sonucu diğerinin olasılığını değiştirir. `gapminder`'dan **yerine koymadan** iki farklı ülke seçersek, ilk seçim ikinci seçimin olasılık uzayını daraltır — tam da bir desteden yerine koymadan iki kart çekmek gibi.

6. maddedeki olayın olasılığını hesaplayalım:

```
mean(gapminder$lifeExp > 70)
```

```
[1] 0.2893192
```

i replace = TRUE vs replace = FALSE

`sample(x, size, replace = TRUE)` aynı birimi birden çok kez seçebilir (bağımsız deneyler). `replace = FALSE` (varsayılan) her birimi en fazla bir kez seçer (bağımlı deneyler) — modül 05'te `slice_sample()` ile yaptığımız örneklemin arkasındaki de budur.

Toplama ve Çarpma Kuralları

Toplama kuralı, birbirini dışlayan (aynı anda gerçekleşemeyen) olaylardan **en az birinin** gerçekleşme olasılığını verir; olasılıklar toplanır. Bir gözlemin Afrika **veya** Asya kıtasından olma olasılığı:

```
p_afrika <- mean(gapminder$continent == "Africa")
p_asya <- mean(gapminder$continent == "Asia")
p_afrika + p_asya
```

```
[1] 0.5985915
```

Bir kıta bir gözlemde yalnızca tek bir değer alabildiği için (bir ülke aynı anda hem Afrikalı hem Asyalı olamaz) bu iki olay birbirini dışlar ve olasılıklar doğrudan toplanabilir.

Çarpma kuralı, **bağımsız** iki olayın **birlikte** gerçekleşme olasılığını verir; olasılıklar çarpılır. Yerine koyarak seçtiğimiz iki gözlemin **ikisinin de** Avrupa kıtasından olma olasılığı:

```
p_avrupa <- mean(gapminder$continent == "Europe")
p_avrupa^2
```

```
[1] 0.044634
```

⚠ Bağımsız değilse çarpma kuralı doğrudan uygulanmaz

Eğer iki seçim **bağımsız değilse** (yerine koymadan seçim gibi), ikinci olasılık ilkine bağlı olarak değişir ve hesaba **koşullu olasılık** girer. Koşullu olasılığın kendisi bu dersin kapsamı dışındadır; burada yalnızca bağımsız durumu işliyoruz.

Rastgele Değişkenler: Kesikli ve Sürekli

Bir **rastgele değişken**, bir deneyin her olası sonucuna bir sayı atayan fonksiyondur. İki türü vardır:



- **Kesikli rastgele değişken:** sayılabilir, genellikle tam sayı değerler alır. Örnek: rastgele seçilen 10 ülkeden kaçının Afrika kıtasından olduğu — 0, 1, 2, ... 10 değerlerinden birini alır.
- **Sürekli rastgele değişken:** bir aralıktaki sonsuz sayıda değeri alabilir. Örnek: yaşam beklentisinin kendisi (`lifeExp`) — 42.6, 42.61, 42.611... gibi ondalıklı herhangi bir değer olabilir.

Bu ayrım önemlidir çünkü her tür için **farklı olasılık dağılımı aileleri** kullanılır.

Olasılık Dağılımları

Bir **olasılık dağılımı**, bir rastgele değişkenin alabileceği her değere (veya değer aralığına) bir olasılık atar. R, en yaygın dağılımlar için dört fonksiyon ailesi sunar: **d** (yoğunluk/kütle), **p** (kümülatif olasılık), **q** (kantil) ve **r** (rastgele üretim) — örneğin normal dağılım için `dnorm`, `pnorm`, `qnorm`, `rnorm`.

Hangi dağılım modeli kullanılmalı?

Binom Dağılımı


İki olasılıklı, sabit deneme sayısı.

Normal Dağılım

Sürekli, ortalamaya göre simetrik.

Poisson Dağılımı

Nadir olaylar, sabit ortalama hız.



Binom Dağılımı: Kesikli Değişkenler İçin


Binom dağılımı, sabit sayıda **bağımsız** denemede (her biri “başarı” ya da “başarısızlık”), belirli bir başarı sayısının olasılığını verir. 10 ülkelik bağımsız bir örnekleme kaç tanesinin Afrika kıtasından çıkacağını modelleyelim (başarı olasılığı, popülasyondaki gerçek Afrika oranı):

```
n_deneme <- 10  
p_basari <- mean(gapminder$continent == "Africa")
```

```
olasiliklar <- dbinom(0:n_deneme, size = n_deneme, prob = p_basari)
data.frame(afrika_sayisi = 0:n_deneme, olasilik = round(olasiliklar, 4))
```

afrika_sayisi	olasilik
0	0.0105
1	0.0604
2	0.1571
3	0.2421
4	0.2448
5	0.1697
6	0.0817
7	0.0270
8	0.0058
9	0.0008
10	0.0000

```
ggplot(data.frame(k = 0:n_deneme, p = olasiliklar), aes(k, p)) +
  geom_col(fill = "#2E6E8E") +
  scale_x_continuous(breaks = 0:n_deneme) +
  labs(x = "Afrika kıtasından ülke sayısı (k)", y = "P(X = k)") +
  theme_minimal()
```



Figür 2: Binom dağılımı: 10 ölkelik bağımsız örnekleme Afrika sayısı

`dbinom(k, size, prob)` tam olarak “ k başarı olasılığı” sorusuna cevap verir. `pbinom()` ise **kümülatif** olasılık verir — “en fazla k ” sorusuna cevaptır. Örneğin, 10 ölkelik örnekleme **en az 3** tanesinin Afrika’dan olma olasılığı:

```
1 - pbinom(2, size = n_deneme, prob = p_basari)
```

```
[1] 0.7719668
```

(“En az 3” = “2 veya daha az değil”; bu yüzden `pbinom(2, ...)`’i 1’den çıkarıyoruz.)

💡 İleri düzey (sınav kapsamı dışı): Ya yerine koymadan seçim yapsaydık?

Yukarıdaki binom modeli **bağımsız denemeleri** varsayar — bu yüzden sayfanın başında `sample(..., replace = TRUE)` kullanmıştık. Ama gerçek anket ve saha araştırmalarında bir ülke ya da katılımcı genellikle **yerine koymadan** seçilir (aynı kişiye anketi iki kez uygulamazsınız). Yerine koymadan seçimde her çekiliş bir öncekine **bağımlıdır** ve teknik olarak doğru dağılım binom değil, **hipergeometrik dağılımdır** (R’da `dhyper()`). Popülasyon örnekleme oranına göre büyükse (bizim durumumuzda olduğu gibi) iki dağılım birbirine çok yaklaşır ve binom yaklaşımı pratikte yeterlidir — bu yüzden bu ders

`dhyper()`'i işlemeyecek, yalnızca varlığını bilmeniz yeterli.


Normal Dağılım: Sürekli Değişkenler İçin

Normal dağılım, ortalama etrafında simetrik, çan eğrisi şeklindeki sürekli dağılımdır. 2007 kesitindeki yaşam beklentisi değerlerinin bu şekle ne kadar uyduğuna bakalım:

```
yb_2007 <- gapminder |> filter(year == 2007) |> pull(lifeExp)
ort <- mean(yb_2007)
ss <- sd(yb_2007)
c(ortalama = ort, standart_sapma = ss)
```

```
ortalama standart_sapma
67.00742      12.07302
```

```
ggplot(data.frame(x = yb_2007), aes(x)) +
  geom_histogram(aes(y = after_stat(density)), bins = 20,
                 fill = "#EAF1F5", color = "#2E6E8E") +
  stat_function(fun = dnorm, args = list(mean = ort, sd = ss),
               color = "firebrick", linewidth = 1) +
  labs(x = "Yaşam beklentisi (2007)", y = "Yoğunluk") +
  theme_minimal()
```



Figür 3: 2007 yaşam beklentisi dağılımı ve normal yaklaşım

⚠ Bu dağılım tam simetrik değil

Modül 04'te gördüğünüz gibi, yaşam beklentisi **sola çarpıktır** — düşük yaşam beklentili birkaç ülke sol kuyruğu uzatır. Normal dağılım yalnızca bir **yaklaşım**dır; aşağıdaki karşılaştırma bu yaklaşımın ne kadar sıkı olduğunu gösterir.

`pnorm()`, normal dağılıma göre kümülatif olasılık verir. Yaşam beklentisi 75'in altında olma olasılığını, normal yaklaşıma göre hesaplayıp gerçek (ampirik) oranla karşılaştıralım:

```
data.frame(
  yontem = c("Normal yaklaşım (pnorm)", "Gerçek (ampirik) oran"),
  olasilik = c(pnorm(75, mean = ort, sd = ss), mean(yb_2007 < 75))
)
```

yontem	olasilik
Normal yaklaşım (pnorm)	0.7460207
Gerçek (ampirik) oran	0.6901408

İki değer birbirine yakın ama özdeş değil — tam olarak yukarıdaki çarpıklık uyarısının öngördüğü küçük sapma.

Rastgele Üretim: `rbinom()` ve `rnorm()`

`d/p/q` fonksiyonları olasılık *hesaplar*; `r` ile başlayanlar (“random”) ise o dağılımdan rastgele veri *üretir*. Bunlar özellikle simülasyon tabanlı analizlerde (ör. bootstrap, güç analizi) kullanılır:

```
set.seed(2026)
rbinom(5, size = n_deneme, prob = p_basari) # 5 simüle örnekleme Afrika sayısı
```

```
[1] 4 4 2 3 4
```

```
rnorm(5, mean = ort, sd = ss) # normal dağılımdan 5 simüle yaşam beklentisi
```

```
[1] 43.37177 80.10510 69.46980 73.05777 79.44456
```

Özet

Not

Bu belgede öğrendikleriniz

- Klasik (teorik) olasılık ile deneysel (ampirik) olasılık; Büyük Sayılar Kanunu
- Deney, örneklem uzayı, olay, bağımsız/bağımlı olay kavramları
- Toplama kuralı (birbirini dışlayan olaylar için) ve çarpma kuralı (bağımsız olaylar için)
- Kesikli ve sürekli rastgele değişken ayrımı
- R’ın dağılım fonksiyon ailesi: `d/p/q/r` örnekleri
- Binom dağılımı (`dbinom`, `pbinom`) ve normal dağılım (`dnorm`, `pnorm`) ile olasılık hesaplama
- `rbinom()/rnorm()` ile bir dağılımdan rastgele veri üretme

Sırada Ne Var?

Bu belgede ürettiğimiz normal yaklaşım aslında **7. oturumda** (07_modul/) işleyeceğimiz **örnekleme dağılımı** ve **Merkezi Limit Teoremi**'nin temelini oluşturuyor: tek tek ülkelerin yaşam beklentisi dağılımı çarpıkken, *örneklem ortalamalarının* dağılımı — örneklem yeterince büyükse — neredeyse her zaman normale yakınsar. Bir sonraki oturumda bunu simülasyonla göstereceğiz.